Как лгать при помощи статистики

Теория вероятностей и математическая статистика · НИЯУ МИФИ

А. Шемендюк

В 1954 году американский журналист Даррелл Хафф выпустил тонкую книжку «How to Lie with Statistics» (Huff 1954 г.). В ней нет ни одной формулы сложнее среднего арифметического, зато есть каталог приёмов, которыми цифры превращают в рекламу, политику и заголовки. Книга стала одной из самых продаваемых книг о статистике и до сих пор читается за вечер. Есть русский перевод: «Как лгать при помощи статистики» (Альпина Паблишер, перевод Е. Лалаян).

Название обманчиво: это не пособие для лжецов, а прививка для читателя. Хафф объясняет, что почти никто не врёт цифрами прямо. Цифры обычно верны; обманывает то, *какие* цифры показали, *как* их нарисовали и *что* о них умолчали. С этого семестра у вас есть всё, чтобы такие приёмы ловить: закон больших чисел, ЦПТ, выборка, среднее и медиана, корреляция. Ниже главные сюжеты книги, каждый привязан к тому, что мы уже разобрали на семинарах.

> Зачем это читать будущему инженеру и физику
>
> Статистику, которую вы увидите в жизни, почти никогда не будете считать сами: её покажут на слайде, в статье, в отчёте или в новости. Умение задать к чужому графику три правильных вопроса полезнее, чем умение посчитать дисперсию. Книга Хаффа учит именно этим вопросам.

Код для этой главы

Все импорты и функции, которые используются в примерах приложения, собраны в одной ячейке. Выполните её первой.

Выборка со встроенным смещением

Осенью 1936 года журнал Literary Digest разослал анкеты миллионам американцев, получил больше двух миллионов ответов и уверенно предсказал победу республиканца Лэндона над Рузвельтом. Рузвельт выиграл с огромным отрывом. Адреса брали из телефонных книг и списков владельцев автомобилей, а в годы Великой депрессии телефон и машина были у обеспеченных людей, которые чаще голосовали за республиканцев. Кроме того, ответили те, кому было не лень отвечать. Джордж Гэллап по выборке в десятки раз меньше предсказал результат верно.

Связь с курсом. Закон больших чисел обещает, что $\bar{x}$ сходится к среднему той совокупности, *из которой на самом деле взяты* наблюдения. Если это не та совокупность, о которой задан вопрос, рост n не

помогает: случайная ошибка порядка $\sigma/\sqrt{n}$ уменьшается, а систематическая (смещение) остаётся какой была. Два миллиона анкет дали очень точную оценку не той величины.

Вопрос, который стоит задать: **кого не спросили?** Опрос на сайте, отзывы покупателей, «9 из 10 стоматологов рекомендуют» всегда отвечают на вопрос о тех, кто попал в выборку.

Удачно выбранное среднее

«Средняя зарплата в компании 72 тысячи» и «типичный сотрудник получает 60 тысяч» могут быть правдой одновременно. Когда распределение несимметрично (доходы, цены квартир, размеры файлов), длинный правый хвост тянет среднее вверх, а медиана остаётся там, где большинство. Хафф иронизирует: выбирая между средним, медианой и модой, можно получить ровно ту цифру, которая нужна, и ни разу не соврать.

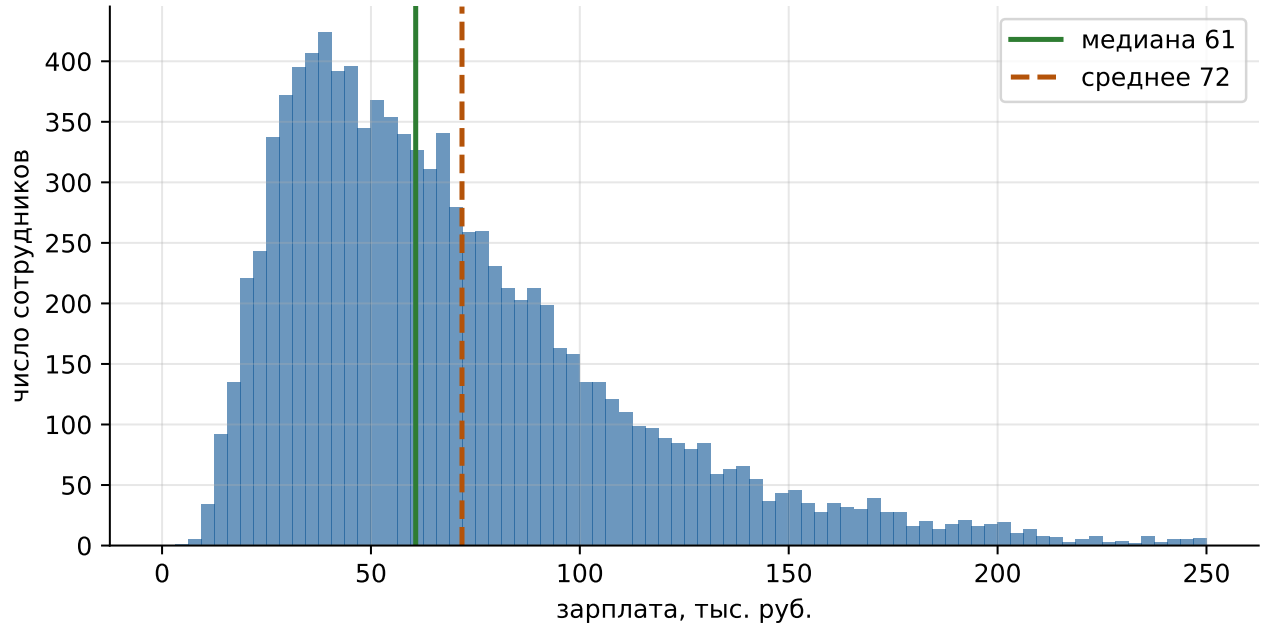


Рисунок 1: Модельные зарплаты 10 000 сотрудников (логнормальный закон, в тыс. руб.). Среднее заметно правее медианы: ниже «средней зарплаты» получает больше 60 % людей.

```
доля получающих меньше среднего: 61.1%
```

Связь с курсом. На семинаре 8 в таблице выборочных характеристик стоят и $\bar{x}$, и медиана, и мода. Теперь видно, зачем все три: для несимметричных данных они отвечают на разные вопросы. Вопрос к любому «в среднем»: **какое именно среднее и как выглядит распределение?**

Маленькие цифры, которых нет

Реклама зубной пасты: «у пользователей нашей пасты на 23 % меньше кариеса». Мелким шрифтом (или вообще нигде) сказано, что в группе было 12 человек. Хафф описывает, как такие результаты получают честно: ставят много маленьких опытов и публикуют удачный.

Проверим, насколько это легко. Пусть паста **ничего не делает**: у каждого ребёнка число кариозных зубов пуассоновское со средним 3, в обеих группах одинаково. Как часто «новая паста» всё равно покажет снижение на 23 % и больше?

```
группы по  12 человек: «эффект» 23 % в 13.6% опытов
группы по  50 человек: «эффект» 23 % в 1.2% опытов
группы по 500 человек: «эффект» 23 % в 0.0% опытов
```

При группах по 12 человек «эффект» выпадает примерно в каждом седьмом опыте. Проведите двадцать таких опытов, и в рекламу почти наверняка попадут два-три. При группах по 500 человек случайность такого не делает.

Связь с курсом. Это ЦПТ в действии: разброс среднего по группе порядка $\sigma/\sqrt{n}$, при $n = 12$ он велик, и разница в 23 % лежит в пределах шума. Вопрос: **сколько было наблюдений и сколько было опытов?**

Близкий сюжет у Хаффа называется «много шума из ничего»: два числа, различие между которыми меньше погрешности измерения (IQ 98 и 101, рейтинг 4,6 и 4,7), подают как реальную разницу. Без указания разброса разность двух средних ничего не говорит.

График «ого!»

Самый простой приём: обрезать ось y. Рост на 3 % становится крутым взлётом, если ось начинается не с нуля, а чуть ниже первого значения.

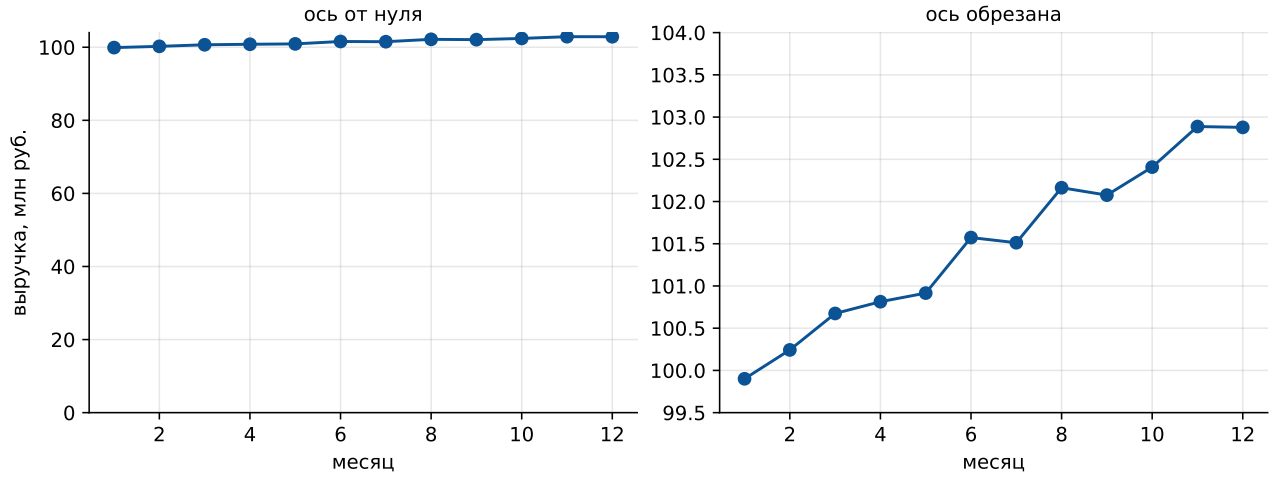


Рисунок 2: Одни и те же данные: выручка выросла с 100 до 103 млн руб. Слева ось от нуля, справа обрезана. Ни одна цифра не изменилась.

Обрезанная ось не всегда обман: иногда интересны именно малые изменения (температура тела, курс валюты). Обман начинается, когда график должен произвести впечатление размера, а показывает только наклон. Вопрос: **откуда начинается ось?**

Одномерная картинка

Зарплата выросла вдвое, и художник рисует мешок с деньгами вдвое выше. Но чтобы мешок не стал тощим, его рисуют вдвое шире, и глаз видит площадь: она выросла **вчетверо**. Если картинка объёмная (бочка, дом), объём вырос в восемь раз.

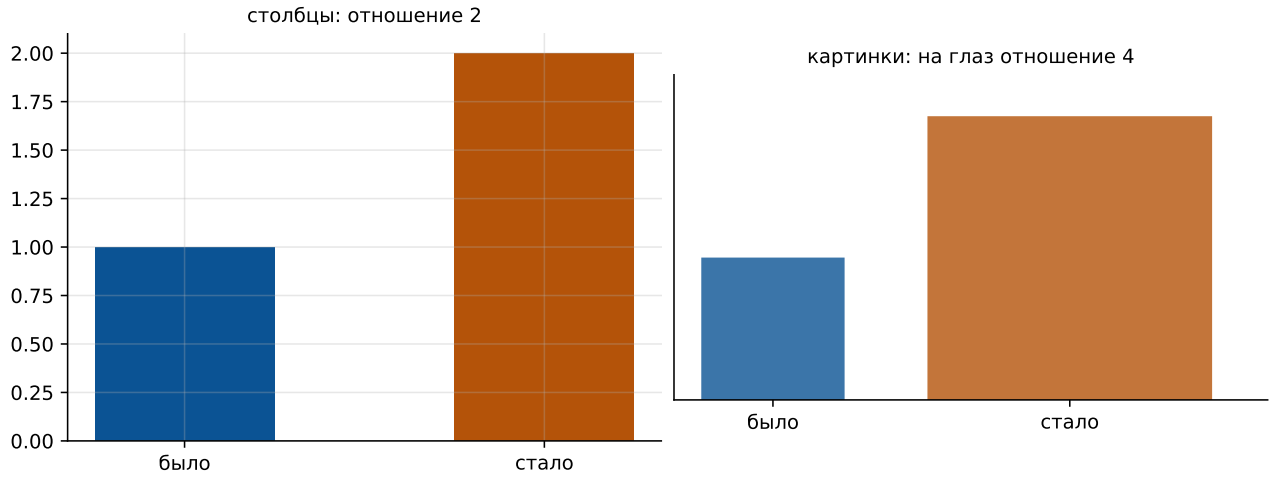


Рисунок 3: Величина выросла в 2 раза. Слева честно: столбец вдвое выше. Справа «картинка»: квадрат со стороной вдвое больше, его площадь в 4 раза больше.

Это тот же эффект, что у гистограммы с неравными интервалами: глаз читает площадь, поэтому на семинаре 8 высоту столбца делят на ширину интервала, $n_i/(nh)$. Вопрос: **что пропорционально числу: высота или площадь?**

После этого, значит, вследствие этого

Курящие студенты учатся хуже некурящих. Значит ли это, что курение вредит учёбе? Может быть, плохие оценки толкают к сигаретам. Может быть, на то и другое влияет третий фактор: характер, режим, компания. Хафф собирает много таких историй: зарплаты пасторов в Массачусетсе росли вместе с ценой рома в Гаване (обе цифры тянул вверх общий рост цен), выпускники колледжей зарабатывают больше (но в колледж и попадали дети из обеспеченных семей).

Связь с курсом. На семинаре 5 мы считали коэффициент корреляции $\rho(X, Y)$. Он измеряет согласованность изменения двух величин, и только её. Корреляция бывает из-за причинной связи в любую сторону, из-за общей причины или просто случайно, если перебрать достаточно много пар величин. Вопрос: **нет ли третьей величины, которая двигает обе?**

Родственный приём Хафф называет «полупривязанной цифрой»: доказывают одно, а предъявляют цифру про другое. «Лекарство убивает 99 % бактерий в пробирке» ничего не говорит о том, вылечит ли оно человека.

Пять вопросов к любой цифре

Книга заканчивается главой о том, как «дать отпор» статистике. Хафф предлагает пять вопросов:

1. **Кто это говорит?** Кому выгоден вывод: производителю, заказчику исследования, автору с готовой гипотезой?
2. **Откуда он это знает?** Как получены данные, кто попал в выборку, сколько было наблюдений?
3. **Чего не хватает?** Объёма выборки, разброса, базы для сравнения, начала оси, какое именно среднее?
4. **Не подменили ли предмет разговора?** Измерили одно, а вывод сделали о другом (анкета вместо поведения, пробирка вместо человека, корреляция вместо причины).
5. **Есть ли в этом смысл?** Правдоподобна ли цифра хотя бы по порядку величины? Точность «до третьего знака» у прикидки сама по себе подозрительна.

Ирония напоследок

У книги есть поучительное продолжение. В 1960-е Хафф работал на табачную индустрию: выступал в Конгрессе США со скепсисом по поводу связи курения и рака, а затем написал рукопись «How to Lie with Smoking Statistics», которая так и не вышла и нашлась в архивах табачных компаний много лет спустя. Автор лучшего учебника по распознаванию статистических уловок применил свои знания к тому, чтобы посеять сомнения в одном из самых надёжно установленных медицинских фактов XX века. Первый вопрос из списка выше, «кто это говорит?», относится и к нему.

Именно поэтому книгу стоит прочитать: умение задавать эти вопросы не зависит от того, кто вас ему научил.

Huff, Darrell. 1954 г. *How to Lie with Statistics*. W. W. Norton.