Семинар 8. Закон больших чисел и ЦПТ. Выборка и её описание

Теория вероятностей и математическая статистика · НИЯУ МИФИ

А. Шемендюк

10 ноября 2026

Краткая сводка

Теория вероятностей позади: по известному закону мы считали вероятности и средние. Статистика решает обратную задачу: закон неизвестен, есть только наблюдения, и по ним надо судить о законе. Мостом служат две предельные теоремы. Здесь они только формулируются; работать с ними будем на следующих семинарах.

Уведомление

Обозначения. В главе используются стандартные обозначения. В задачнике Гмурмана то же самое записано иначе:

Здесь	Гмурман
$\bar{x}$, выборочное среднее	$\bar{x}$
$\hat{\sigma}^2 = \frac{1}{n}\sum(x_i - \bar{x})^2$	D
$s^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2$	s^2
$\hat{F}_n(x)$, эмпирическая функция распределения	$F^*(x)$
$w_i = n_i/n$	W_i
$\mathrm{E}X$, $\mathrm{Var}X$	$M(X)$, $D(X)$
$\Phi(t) = \mathbb{P}(Z \leqslant t)$, $Z \sim N(0,1)$	$\Phi(t) - 0{,}5$

От вероятности к статистике

Пусть $X_1, \dots, X_n$ независимы и одинаково распределены:

$$X_1, \dots, X_n \sim F, \qquad X_i \perp\!\!\!\perp X_j \ (i \neq j),$$

где F есть **какая угодно** функция распределения (дискретная, непрерывная, несимметричная). Раз закон у всех X_i один и тот же, у них одни и те же среднее и дисперсия:

$$\mathrm{E}X_i = \mu, \qquad \mathrm{Var}X_i = \sigma^2 \qquad \text{для всех } i = 1, \dots, n$$

(предполагаем, что они существуют и $0 < \sigma^2 < \infty$). Обозначим $S_n = X_1 + \cdots + X_n$ и $\bar{X}_n = S_n/n$. По свойствам среднего и дисперсии (для дисперсии нужна независимость)

$$\mathrm{E}S_n = n\mu, \quad \mathrm{Var}S_n = n\sigma^2, \qquad \mathrm{E}\bar{X}_n = \mu, \quad \mathrm{Var}\bar{X}_n = \frac{\sigma^2}{n}.$$

- **Неравенство Чебышева.** Для любой величины X с конечной дисперсией и любого $\varepsilon > 0$

$$\mathbb{P}(|X - \mathrm{E}X| \geqslant \varepsilon) \leqslant \frac{\mathrm{Var}X}{\varepsilon^2}.$$

- **Закон больших чисел.** Применяя неравенство к $\bar{X}_n$: $\mathbb{P}(|\bar{X}_n - \mu| \geqslant \varepsilon) \leqslant \dfrac{\sigma^2}{n\varepsilon^2} \to 0$. Среднее многих наблюдений приближается к μ. Частный случай (теорема Бернулли): относительная частота события в n испытаниях приближается к его вероятности p.

- **Центральная предельная теорема.** Стандартизуем сумму: вычтем её среднее и разделим на стандартное отклонение. Тогда при любом F с конечной дисперсией для каждого t

$$\mathbb{P}\Big(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leqslant t\Big) = \mathbb{P}\Big(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leqslant t\Big) \xrightarrow[n\to\infty]{} \Phi(t).$$

  От закона F в ответе остались только два числа, μ и σ: форма F при больших n забывается. На практике теорему применяют в виде приближения

$$S_n \approx N(n\mu,\, n\sigma^2), \qquad \bar{X}_n \approx N\Big(\mu,\, \frac{\sigma^2}{n}\Big).$$

  Пример. Бросают 100 игральных костей, X_i есть очко на i-й. Закон X_i равномерный на $\{1, \ldots, 6\}$, совсем не нормальный, но $\mu = 3{,}5$, $\sigma^2 = \frac{91}{6} - 3{,}5^2 = \frac{35}{12}$ одни и те же у всех костей. Для суммы очков $\mathrm{E}S_{100} = 350$, $\mathrm{Var}S_{100} = \frac{3500}{12} \approx 291{,}7$, $\sigma(S_{100}) \approx 17{,}08$, и по ЦПТ

$$\mathbb{P}(330 \leqslant S_{100} \leqslant 370) \approx \Phi\Big(\frac{20}{17{,}08}\Big) - \Phi\Big(-\frac{20}{17{,}08}\Big) = 2\Phi(1{,}17) - 1 \approx 0{,}758.$$

  Точное значение 0,770; разница в основном из-за того, что сумма целочисленна (если взять границы $329{,}5$ и $370{,}5$, получится 0,770).

  Частный случай: X_i принимает значения 1 и 0 с вероятностями p и $q = 1-p$ (успех в i-м испытании Бернулли). Тогда $\mu = p$, $\sigma^2 = pq$, $S_n = k$ есть число успехов, и ЦПТ превращается в интегральную теорему Муавра–Лапласа: $\mathbb{P}(a \leqslant k \leqslant b) \approx \Phi\big(\frac{b-np}{\sqrt{npq}}\big) - \Phi\big(\frac{a-np}{\sqrt{npq}}\big)$.

Что из этого берёт статистика:

- выборочное среднее $\bar{x}$ годится как приближение для μ (закон больших чисел);
- его ошибка имеет порядок $\sigma/\sqrt{n}$ и приближённо нормальна (ЦПТ): чтобы уменьшить ошибку вдвое, наблюдений нужно вчетверо больше;
- по той же причине эмпирическая функция распределения $\widehat{F}_n(x)$ при больших n близка к истинной $F(x)$ (теорема Гливенко).

Прочитайте за вечер: «Как лгать при помощи статистики»

С этого семинара начинается статистика, а с ней и умение не верить цифрам на слово. Классическая книжка Даррелла Хаффа (1954, есть русский перевод) показывает, как честными цифрами вводят в заблуждение: выборка не из той совокупности, «среднее» вместо медианы, группа из 12 человек, обрезанная ось графика, корреляция вместо причины. Формул там нет, а каждый приём ловится тем, что мы прошли в этом семестре.
Краткий пересказ с примерами есть в приложении к книге курса.

Выборка и её распределение

Генеральная совокупность есть случайная величина X с неизвестным законом. **Выборка** объёма n: значения $x_1, \dots, x_n$, полученные в n независимых наблюдениях X.

- **Вариационный ряд:** выборка, упорядоченная по возрастанию, $x_{(1)} \leqslant \dots \leqslant x_{(n)}$.
- **Статистический ряд:** различные значения (варианты) x_i, их частоты n_i ($\sum n_i = n$) и относительные частоты $w_i = n_i/n$ ($\sum w_i = 1$). Это выборочный аналог ряда распределения.
- **Эмпирическая функция распределения:**

$$\hat{F}_n(x) = \frac{\text{число } x_i \leqslant x}{n}.$$

  Ступенчатая, от 0 до 1, в каждой варианте x_i прыгает на w_i. Выборочный аналог $F(x)$.
- **Полигон частот:** ломаная через точки (x_i, w_i). Для дискретных данных.
- **Группировка и гистограмма.** Непрерывные данные разбивают на интервалы длины h, n_i есть число наблюдений в i-м интервале. Над интервалом строят прямоугольник высотой $\dfrac{w_i}{h} = \dfrac{n_i}{nh}$. Площадь всей гистограммы равна 1, гистограмма есть выборочный аналог плотности $f(x)$.

Числовые характеристики выборки

Выборочная	Формула	Аналог
среднее	$\bar{x} = \frac{1}{n}\sum x_i = \sum x_i w_i$	EX
дисперсия	$\hat{\sigma}^2 = \frac{1}{n}\sum (x_i - \bar{x})^2 = \overline{x^2} - \bar{x}^2$	Var$X$
исправленная дисперсия	$s^2 = \frac{n}{n-1}\,\hat{\sigma}^2$	Var$X$
медиана	средний элемент вариационного ряда (при чётном n полусумма двух средних)	медиана X
мода	варианта с наибольшей частотой	мода X
размах	$x_{(n)} - x_{(1)}$	

Для сгруппированных данных x_i в формулах заменяют серединами интервалов. Почему у s^2 делитель $n-1$ и какая из двух дисперсий «правильная», разберём на следующем семинаре.

Линейная замена. Если $y_i = a + bx_i$, то $\bar{y} = a + b\bar{x}$, $\hat{\sigma}_y^2 = b^2\hat{\sigma}_x^2$ (то же для s^2). Удобно для расчётов вручную: середины интервалов заменяют на $u_i = (x_i - C)/h$, где C есть середина в центре таблицы, а h есть шаг. Тогда u_i будут целыми числами $\dots, -1, 0, 1, \dots$, и $\bar{x} = C + h\bar{u}$, $\hat{\sigma}_x^2 = h^2\hat{\sigma}_u^2$.

Блок A. Закон больших чисел и ЦПТ

Задача 1

Прибор измеряет величину μ со случайной ошибкой: среднее ошибки 0, стандартное отклонение $\sigma = 0{,}2$. Результатом считают среднее $\bar{X}$ из n независимых измерений. Сколько нужно измерений, чтобы $|\bar{X} - \mu| < 0{,}05$ с вероятностью не меньше 0,95?

а) Ответить с помощью ЦПТ. б) Ответить с помощью неравенства Чебышева (оно не требует знать закон ошибки). Сравнить.

Блок B. Выборка и её распределение

Задача 2

Проверено 20 партий изделий; число бракованных изделий в партиях:

$$2,\ 1,\ 0,\ 3,\ 1,\ 1,\ 2,\ 4,\ 0,\ 1,\ 2,\ 3,\ 1,\ 0,\ 2,\ 1,\ 3,\ 0,\ 1,\ 2.$$

а) Записать вариационный ряд и статистический ряд (частоты и относительные частоты). б) Найти эмпирическую функцию распределения $\hat{F}_{20}(x)$ и построить её график. в) Построить полигон относительных частот. г) По $\hat{F}_{20}$ найти долю партий, в которых бракованных изделий не больше двух, и долю, в которых их больше одного.

Задача 3

Измерено время ответа сервера (мс) на 50 запросов. Результаты сгруппированы:

Время, мс	$[10, 12)$	$[12, 14)$	$[14, 16)$	$[16, 18)$	$[18, 20)$
Число запросов n_i	4	11	17	12	6

а) Построить гистограмму относительных частот и проверить, что её площадь равна 1. б) Найти долю запросов со временем от 14 до 18 мс. в) Оценить по гистограмме долю запросов со временем от 13 до 17 мс. г) Найти значения $\hat{F}_{50}$ на границах интервалов.

Блок C. Числовые характеристики выборки

Задача 4

Для выборки из задачи 2 найти выборочное среднее $\bar{x}$, дисперсии $\hat{\sigma}^2$ и s^2, медиану, моду и размах.

Задача 5

Для сгруппированных данных задачи 3 найти $\bar{x}$, $\widehat{\sigma}^2$ и s^2, перейдя к условным вариантам $u = (x - 15)/2$, где x есть середина интервала.

Задача 6

По данным задачи 3 (используя результат задачи 5) оценить, насколько выборочное среднее $\bar{x}$ может отличаться от истинного среднего времени ответа μ. Указать диапазон, в котором μ лежит «почти наверняка», если считать, что $\sigma \approx s$ и ЦПТ применима.

Задачи для самостоятельной работы

1. Каждое из 100 чисел округляют до целого; ошибки округления независимы и равномерны на $(-0{,}5;\ 0{,}5)$. Оценить вероятность того, что суммарная ошибка по модулю меньше 5: а) по ЦПТ; б) по неравенству Чебышева.
2. В опросе участвуют 400 человек. Доля сторонников некоторого решения в генеральной совокупности равна $p = 0{,}5$. Найти вероятность того, что доля сторонников в выборке отличается от p меньше чем на 0,05.
3. Оценки 10 студентов: $3, 4, 5, 4, 3, 5, 4, 2, 4, 5$. Составить статистический ряд, найти $\widehat{F}_{10}(x)$, $\bar{x}$, $\widehat{\sigma}^2$, s^2, медиану и моду.
4. Эмпирическая функция распределения выборки объёма 20 равна 0 при $x < 1$, 0,15 при $1 \leqslant x < 2$, 0,40 при $2 \leqslant x < 3$, 0,80 при $3 \leqslant x < 5$ и 1 при $x \geqslant 5$. Восстановить статистический ряд (частоты n_i) и найти $\bar{x}$.
5. Средняя температура по выборке равна $-2{,}5$ °C, $s = 4$ °C. Найти среднее и s в градусах Фаренгейта ($t_F = 32 + 1{,}8\,t_C$).